



MEMORIA PROYECTO B

Almacenes de Datos — Curso 2025/2026

Integrantes del grupo

Rubén Subires Hidalgo

Iván Galiano Navarro

Juan de Dios Cobos Hernández

Roberto Delgado Alcázar

TAREA 1. Diseño Conceptual y Lógico

1.1. Análisis del Modelo Relacional Origen

El primer paso consistía en **crear la base de datos operacional** en *SQL Server Management Studio* (SSMS). Para ello se ejecutaron los dos archivos SQL proporcionados en el orden correcto: primero el archivo DDL para crear las tablas y a continuación el archivo DML para poblarlas. A partir de ese punto fue posible analizar la organización de la base de datos original y comenzar con los diseños del almacén.

La base de datos operacional contiene las siguientes tablas principales que sirven como fuente para el proceso ETL: **games** (partidos), **teams** (equipos), **leagues** (ligas), **seasons** (temporadas), **rounds** (jornadas), **events** (eventos), **grounds** (estadios), **countries**, **cities** y **continents**. El volumen de datos cubre seis temporadas de la Primera División española (2012/13 a 2017/18).

1.2. Diseño Conceptual

Para el modelo conceptual se adoptó un **diagrama estrella** cuyo eje central es el hecho **Partido** (identificado por su *game_id*). A partir de este hecho se organizan **cinco dimensiones** principales:

- **Eventos:**
 - Comprende el título de la liga, la temporada y las fechas de inicio y fin de la competición.
- **Equipos:**
 - Contiene nombre del equipo, ciudad, país y continente.
- **Fecha:**
 - Día de la semana, día, mes, trimestre y año del partido.
- **Estadio:**
 - Nombre, capacidad, ciudad, país y equipo propietario.
- **Jornada:**
 - Título, posición (pos) y fechas de inicio y fin de la ronda.




Figura 1. Diagrama conceptual del almacén de datos

1.3. Diseño Lógico

Para el diseño lógico se siguió un **Esquema en Estrella**: la tabla de hechos ocupa el centro del modelo y las tablas de dimensiones se distribuyen a su alrededor, cada una conectada mediante una clave foránea autogenerada.

Tabla de Hechos: Partido

Es la tabla central que conecta todo el modelo. Sus campos son:

Campo	Tipo	Descripción
game_id	INT IDENTITY	Clave primaria autogenerada del partido
date_key	INT (FK)	Referencia a Dim_Time
team1_id	INT (FK)	Equipo local — referencia a Dim_Teams
team2_id	INT (FK)	Equipo visitante — referencia a Dim_Teams
ground_id	INT (FK)	Estadio — referencia a Dim_Estadios

Campo	Tipo	Descripción
event_id	INT (FK)	Competición — referencia a Dim_Events
round_id	INT (FK)	Jornada — referencia a Dim_Jornada
goles_local	INT	Goles del equipo local en tiempo reglamentario
goles_visitante	INT	Goles del equipo visitante en tiempo reglamentario

Tablas de Dimensiones

Nota: todos los IDs son autogenerados mediante IDENTITY(1,1) y no utilizan los IDs de la BD de origen.

Dim_Events

Campo	Tipo	Descripción
event_id	INT IDENTITY	Clave primaria autogenerada
league_title	NVARCHAR(100)	Nombre de la liga
season_title	NVARCHAR(100)	Denominación de la temporada
start_at	DATE	Fecha de inicio del evento
end_at	DATE	Fecha de fin del evento

Dim_Jornada

Campo	Tipo	Descripción
jornada_id	INT IDENTITY	Clave primaria autogenerada
round_id_src	INT	ID de la jornada en la BD origen
titulo	NVARCHAR(50)	Descripción de la jornada
pos	INT	Número de orden de la jornada
event_id	INT (FK)	Referencia a Dim_Events
start_at	DATE	Fecha de inicio de la jornada
end_at	DATE	Fecha de fin de la jornada

Dim_Time

Campo	Tipo	Descripción
date_key	INT IDENTITY	Clave primaria autogenerada
day	INT	Día del mes (1-31)
month	INT	Mes del año (1-12)
year	INT	Año
quarter	INT	Trimestre (1-4)
day_of_week	INT	Día de la semana (1=Dom ... 7=Sáb)

Dim_Estadios

Campo	Tipo	Descripción
ground_id	INT IDENTITY	Clave primaria autogenerada
stadium_name	NVARCHAR(150)	Nombre oficial del estadio
capacity	INT	Aforo máximo
city_name	NVARCHAR(100)	Ciudad donde se ubica
country_name	NVARCHAR(100)	País donde se ubica
team_id	INT (FK)	Equipo propietario — referencia a Dim_Teams

Dim_Teams

Campo	Tipo	Descripción
team_id	INT IDENTITY	Clave primaria autogenerada
team_name	NVARCHAR(100)	Nombre del equipo
city_name	NVARCHAR(100)	Ciudad del equipo
country_name	NVARCHAR(100)	País del equipo
continent_name	NVARCHAR(100)	Continente del equipo

Como en un partido intervienen dos equipos, **Dim_Teams** se conecta dos veces a la tabla de hechos: como equipo local (*team1_id*) y como equipo visitante (*team2_id*).

Partido ERD Diagram




Figura 2. Diagrama lógico — Esquema en Estrella del almacén de datos

TAREA 2. Integración de Datos (ETL)

En este apartado se describe el proceso de **Extracción, Transformación y Carga** (ETL) desarrollado en **SQL Server Integration Services** (SSIS) dentro de Visual Studio 2022 para alimentar el almacén de datos.

2.1. Fuentes de Datos Adicionales

Para complementar la información relacional inicial y cubrir atributos ausentes en la base de datos de origen, se generaron mediante herramientas de inteligencia artificial tres ficheros CSV adicionales:

- **datos_dim_teams.csv:**
 - Incorpora el continente de procedencia de cada club y las ciudades que faltaban en la BD operacional.
- **datos_dim_estadios.csv:**
 - Introduce el nombre, capacidad y ciudad de los 42 estadios de los equipos participantes, dato ausente en la tabla grounds de origen.
- **datos_dim_time.csv:**
 - Proporciona un calendario precalculado con todos los fines de semana de jornada de las seis temporadas (2012/13 a 2017/18).

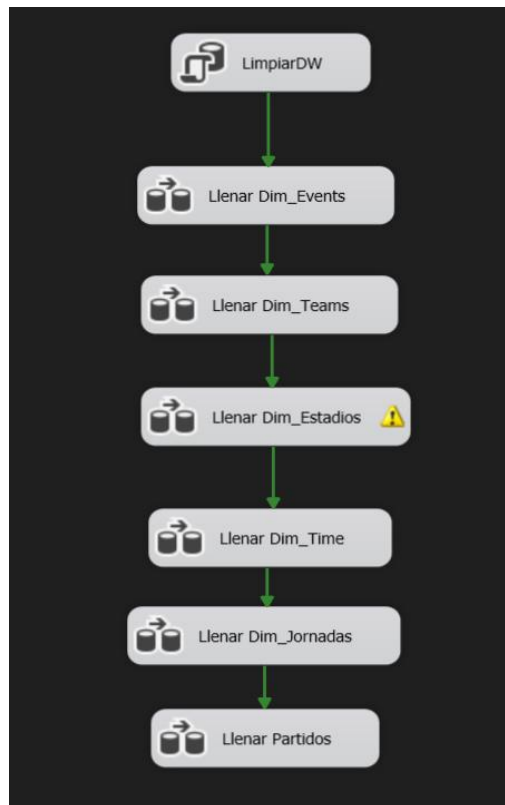


Figura 3. Flujo de control general del ETL

2.2. Autogeneración de IDs y Estrategia de Carga

Para asegurar la **independencia del almacén** respecto al sistema operacional de origen, los IDs de todas las tablas de dimensiones son autogenerados mediante la propiedad **IDENTITY(1,1)** en las tablas de destino.

Para garantizar la integridad referencial, el orden de ejecución del proceso ETL sigue una secuencia estricta:

- **Fase 1 — Carga de Dimensiones:**
 - Se cargan secuencialmente Dim_Events, Dim_Teams, Dim_Estadios, Dim_Time y Dim_Jornada.
- **Fase 2 — Carga de la Tabla de Hechos:**
 - Una vez listas todas las dimensiones, se ejecuta la carga de Partido realizando los Lookups necesarios para resolver cada clave foránea.

2.3. Diseño del ETL en Integration Services (SSIS)

El proyecto SSIS se estructuró en **seis paquetes independientes**, coordinados mediante restricciones de precedencia en el Control Flow.

- **Dim_Events.dtsx:**
 - OLE DB Source sobre events, con Merge Join contra leagues y seasons.
- **Dim_Teams.dtsx:**
 - Flat File Source desde datos_dim_teams.csv. Carga directa sin Lookups.
- **Dim_Estadios.dtsx:**
 - Flat File Source desde datos_dim_estadios.csv, con Lookup contra Dim_Teams para resolver team_id.
- **Dim_Time.dtsx:**
 - Flat File Source desde datos_dim_time.csv con conversión de tipos a entero.
- **Dim_Jornada.dtsx:**
 - OLE DB Source sobre rounds, cadena de cuatro Lookups para resolver el event_id del DW.
- **Partido.dtsx:**
 - Paquete principal con cadena de ocho Lookups para resolver todas las claves foráneas.



Figura 4. Flujo de datos del paquete Partido.dtsx

Cadena de componentes del paquete Partido.dtsx:

Componente	Acción
cargar GAMES	OLE DB Source — tabla games de Futbol_DB
Lookup 1	rounds: resuelve round_id → event_id_src
Lookup 2	events: resuelve event_id_src → league_id + season_id
Lookup 3a	leagues: resuelve league_id → league_title
Conversión de datos	Convierte league_title a tipo compatible con Dim_Events
Lookup 3b	seasons: resuelve season_id → season_title
Conversión de datos 1	Convierte season_title a tipo compatible con Dim_Events
Lookup 3c	Dim_Events (DW): resuelve league_title+season_title → event_id_DW
Lookup 4	teams: resuelve team1_id → team1_name
Conversión de datos 2	Convierte team1_name a tipo compatible con Dim_Teams
Lookup 4b	Dim_Teams (DW): resuelve team1_name → team1_id_DW
Lookup 5	teams: resuelve team2_id → team2_name
Conversión de datos 3	Convierte team2_name a tipo compatible con Dim_Teams
Lookup 5b	Dim_Teams (DW): resuelve team2_name → team2_id_DW
Columna derivada	Extrae day_num, month_num, year_num desde play_at
Lookup 6	Dim_Time (DW): resuelve day+month+year → date_key_DW
Lookup 7	Dim_Estadios (DW): resuelve ground_id → ground_id_DW
Lookup 8	Dim_Jornada (DW): resuelve round_id → jornada_id_DW
Destino de OLE DB	Tabla Partido de Futbol_DW

A continuación, se muestra un ejemplo del flujo de datos para la dimensión Dim_Events:

Tras la ejecución del flujo de datos para Dim_Events, el almacén queda con los siguientes datos:

	event_id	league_title	season_title	start_at	end_at
1	1	Primera División	2017/18	2017-07-01	2018-07-01
2	2	Primera División	2016/17	2016-07-01	2017-07-01
3	3	Primera División	2015/16	2015-08-21	2016-08-21
4	4	Primera División	2014/15	2014-08-23	2015-08-23
5	5	Primera División	2013/14	2013-08-17	2014-08-17
6	6	Primera División	2012/13	2012-08-18	2013-08-18

Figura 7. Contenido de Dim_Events tras la carga ETL

TAREA 3. Análisis de Datos — Cubo OLAP

En este apartado se describe el proceso de creación del cubo analítico y su explotación mediante el lenguaje **MDX**.

3.1. Creación y Configuración del Cubo Analítico

A partir de las tablas del almacén se modeló en SSAS el cubo denominado **CuboFutbol**. Se realizaron dos acciones principales:

Definición de Medidas

Medida	Fórmula / Origen	Descripción
Recuento Partido	COUNT(*)	Volumen total de partidos disputados
Total Goles	goles_local + goles_visitante	Cómputo global de anotaciones
Goles Local	SUM(goles_local)	Total de goles del equipo de casa
Goles Visitante	SUM(goles_visitante)	Total de goles del equipo visitante
Victoria Local	CASE WHEN goles_local > goles_visitante THEN 1 ELSE 0	Contador booleano de victorias locales
Victoria Visitante	CASE WHEN goles_visitante > goles_local THEN 1 ELSE 0	Contador booleano de victorias visitantes
Empates	CASE WHEN goles_local = goles_visitante THEN 1 ELSE 0	Contador booleano de empates

Jerarquías de Usuario

- **Calendario Temporal:**
 - Año → Trimestre → Mes → Día + Nombre_dia_semana.
- **Jornadas:**
 - Evento → Orden_jornada → Jornada.
- **Geografía de Equipos:**
 - Continente → País → Ciudad → Nombre_equipo.
- **Ubicación de Estadios:**
 - Filtra y agrupa encuentros según el recinto deportivo.




Figura 8. Árbol de dimensiones del cubo

3.2. Explotación del Cubo mediante Consultas MDX

Se diseñaron y ejecutaron un total de **15 consultas MDX** agrupadas en tres bloques analíticos:

- **Bloque 1 — Análisis General y Evolución Temporal (Consultas 1-5, 10, 11, 14 y 15):**
 - Totales de partidos y goles, evolución por temporada y concentración mensual de actividad.
- **Bloque 2 — Rendimiento y Comparativa de Equipos (Consultas 6-9):**
 - Rankings Top 15 de equipos más efectivos en casa y fuera, y porcentajes de victoria por club.
- **Bloque 3 — Detalles de Estadios (Consultas 12 y 13):**
 - Estadísticas por estadio y dinámicas específicas de las jornadas del campeonato.

Campos Calculados en la DSV

Tabla de Hechos: Partido

Campo calculado	Fórmula SQL	Función
Total_Goles	goles_local + goles_visitante	Suma el total de goles. Métrica base para el análisis de goleo.
Victoria_Local	CASE WHEN goles_local > goles_visitante THEN 1 ELSE 0 END	Devuelve 1 si ganó el local. Genera el total de victorias locales al sumarse.
Victoria_Visitante	CASE WHEN goles_visitante > goles_local THEN 1 ELSE 0 END	Devuelve 1 si ganó el visitante. Aísla el rendimiento fuera de casa.
Empates	CASE WHEN goles_local = goles_visitante THEN 1 ELSE 0 END	Devuelve 1 si el partido terminó en tablas.

Dimensión Temporal: Dim_Time

Campo calculado	Descripción
Mes_Texto	Convierte el número del mes (1-12) en su etiqueta en español para una visualización limpia.
Periodo_Anio_Mes	Genera clave cronológica YYYY-MM. Soluciona el orden de meses en MDX y evita agrupaciones incorrectas entre años.

TAREA 4. Cuadro de Mando en Power BI

En este apartado se describe el cuadro de mando interactivo desarrollado en **Power BI**. El informe se estructura en tres páginas temáticas:

Página 1 — Visión General de Goles

Incluye un **deslizador de años** para acotar el periodo. Visualizaciones:

- **Recuento de goles por competición:**
 - Número total de goles por competición desglosado por años.
- **Evolución mensual de goles:**
 - Gráfico de barras con la evolución de goles por mes.
- **Desglose de goles por temporada:**
 - Vista comparativa de los tantos marcados en cada curso.
- **Top 10 temporadas con más goles.**




Figura 9. Página 1 del cuadro de mando — Visión General de Goles




Figura 10. Página 2 del cuadro de mando — Análisis de Equipos

Página 2 — Análisis de Equipos

- **Top 15 equipos goleadores de la Liga.**
- **Partidos del Real Madrid en domingo:**
 - Muestra cómo decrece la frecuencia de jugar en ese día.
- **Balance de goles en El Clásico:**
 - Tabla comparativa favorable al FC Barcelona.
- **Probabilidades de victoria en casa.**
- **Partidos en ciudades andaluzas:**
 - Gráfico circular por ciudad.

Página 3 — Análisis por Estadio

Implementa un **buscador por estadio** para explorar estadísticas concretas de cada recinto:

- **Número de encuentros y goles en el campo seleccionado.**
- **Jornadas con más goles:**
 - Gráfico de barras decreciente con goles por jornada en ese estadio.
- **Relación entre partidos y goles:**
 - Gráfico de dispersión para visualizar si la producción goleadora supera el volumen de partidos.



Figura 11. Página 3 del cuadro de mando — Análisis por Estadio

Anexo - Dificultades Encontradas

Fallos en SSIS al cargar las Jornadas

El flujo de control en Visual Studio no insertaba los datos en la tabla de destino "jornadas" de la base de datos Futbol_DW. El flujo se interrumpía por errores de mapeo o conversión.

Para solucionarlo se depuró el paquete ETL paso a paso para corregir el componente OLE DB y los tipos de datos. Se verificó con SSMS mediante sentencias `SELECT` que los registros se consolidaran correctamente.

Error al procesar la Dimensión de Tiempo

El cubo de Analysis Services (SSAS) fallaba al procesarse debido a claves duplicadas y relaciones de atributos mal enlazadas en la dimensión de tiempo.

Como solución se rediseñó la estructura de las relaciones de atributos en el diseñador de dimensiones, asegurando claves de negocio únicas para cada nivel y permitiendo un procesamiento limpio.

Ordenación alfabética e incorrecta de los Meses

El atributo Mes mostraba los meses sueltos ("Agosto", "Septiembre") de forma alfabética (poniendo "Abril" antes que "Enero") y mezclando datos de distintas temporadas.

Para solucionarlo se configuró el atributo en SSAS para formatear la etiqueta como `YYYY-MM` (ej. `2017-08`) y se cambió la propiedad OrderBy para forzar la ordenación según su clave cronológica real.

Error en el cálculo de "Victoria Visitante" en la DSV

En la Vista de Origen de Datos, la columna lógica "Victoria Visitante" usaba la misma fórmula que la local ($\text{goles_local} > \text{goles_visitante}$), lo que distorsionaba por completo las métricas del cubo.

Se corrigió la expresión condicional en el esquema por $\text{goles_visitante} > \text{goles_local}$, garantizando la integridad de los datos para el análisis.

Pérdida de claves naturales en la dimensión de Eventos

Al cargar Dim_Events, el motor autogeneraba IDs nuevos (169, 170...) en lugar de respetar los IDs originales (1 al 6). Esto hacía que el Lookup (Búsqueda) de Jornadas fallara al no encontrar coincidencias.

Para solucionarlo se activó la opción "Carga rápida con mantenimiento de valores de identidad" (`FastLoadKeepIdentity = True`) en el destino OLE DB del paquete SSIS, restableciendo los enlaces correctos.

Bibliografía

Documentación Oficial

- Microsoft Learn. (2024). *SQL Server Integration Services (SSIS) Documentation*. Recuperado de <https://learn.microsoft.com/en-us/sql/integration-services/>
- Microsoft Learn. (2024). *SQL Server Analysis Services (SSAS) Documentation*. Recuperado de <https://learn.microsoft.com/en-us/analysis-services/>
- Microsoft Learn. (2024). *Power BI Documentation*. Recuperado de <https://learn.microsoft.com/en-us/power-bi/>
- Microsoft Learn. (2024). *SQL Server Management Studio (SSMS) Documentation*. Recuperado de <https://learn.microsoft.com/en-us/sql/ssms/>

Fuentes de Datos

- OpenFootball. (2024). *Spain Football Dataset*. Repositorio GitHub. Recuperado de <https://github.com/openfootball/espana> (FINALMENTE NO SE HA USADO)

Herramientas Utilizadas

- Visual Studio 2022 Community Edition
 - SQL Server Management Studio 19
 - Power BI Desktop
 - Modelos de Lenguaje de IA (Claude, ChatGPT, u otros)
-