

MEMORIA PROYECTO B GRUPO 1



Grupo formado por:

- Rubén Subires Hidalgo
- Iván Galiano Navarro
- Juan de Dios Cobos Hernández
- Roberto Delgado Alcázar

TAREA 1. Diseño conceptual y lógico

En este apartado se describe el proceso de creación del almacén de datos para los partidos de fútbol de *openfootball*. El objetivo es **estructurar** la información original para poder **analizarla** posteriormente.


1.1. Análisis del Modelo Relacional Origen

El primer paso fue **crear una base de datos vacía** en *SQL Server Management Studio* (SSMS). Después, ejecutamos los dos archivos SQL proporcionados en el orden correcto: primero el archivo DDL para crear las tablas y luego el archivo con los datos para rellenarlas. A partir de ahí, pudimos ver cómo estaba organizada la base de datos original para empezar con nuestros diseños.

1.2. Diseño Conceptual

Para el modelo conceptual, utilizamos un diagrama donde el punto central es el **Partido** (identificado por su *Game_id*). A partir de este hecho central, organizamos la información en **cinco dimensiones** principales con sus respectivos atributos:

- **Eventos:** Incluye el evento deportivo, el título de la liga (*League_title*), la temporada (*Season_title*) y las fechas en las que empieza y acaba.
- **Equipos:** Contiene el nombre del equipo, la ciudad, el país y el continente al que pertenece.
- **Fecha:** Se divide en el día de la semana, el día, el mes, el trimestre y el año del partido.
- **Estadio:** Almacena el nombre del estadio, su capacidad, la ciudad (*Nombre_ciudad*) y el país (*Nombre_pais*) donde se ubica.
- **Jornada:** Permite clasificar el partido según la jornada y la ronda, incluyendo el título, la posición (*Pos*) y las fechas en las que empieza y acaba dicho periodo.



1.3. Diseño Lógico

Para el diseño lógico, organizamos las tablas siguiendo un **Esquema en Estrella**. En el centro se sitúa la tabla de hechos y a su alrededor las tablas de dimensiones.

Tabla de Hechos: **Partido**

Es la tabla central que conecta todo el modelo. Contiene:

- **Claves de conexión:** Los identificadores para unirse a las dimensiones (**date_key**, **team1_id**, **team2_id**, **ground_id**, **event_id** y **jornada_id**).
- **Medidas:** Los campos numéricos para realizar los análisis, que en este modelo definitivo corresponden a **goles_local** y **goles_visitante**.


Tablas de Dimensiones

Tal y como pedía el proyecto, todos los identificadores de estas tablas son claves autogenerated y no utilizan los IDs de la base de datos original.

- **Dim_Events:** Guarda la información de la liga, temporada y las fechas de inicio y fin del evento.
- **Dim_Jornada:** Almacena los datos de las jornadas o rondas, incluyendo su título, posición (**pos**), fechas y su relación con el evento.
- **Dim_Time:** Desglosa la fecha en campos independientes (**day**, **month**, **year**, **quarter** y **day_of_week**) para facilitar los filtros temporales.
- **Dim_Grounds:** Almacena el nombre del estadio, su capacidad, ciudad, país y el identificador del equipo.
- **Dim_Teams:** Guarda los datos del equipo, ciudad, país y continente. Como en un partido juegan dos equipos, esta tabla se conecta dos veces a la tabla central: una para el equipo local (**team1_id**) y otra para el visitante (**team2_id**).

(Diagrama en la siguiente página)

Partido ERD Diagram



TAREA 2: Integración de datos

En este apartado se describe el proceso de **Extracción, Transformación y Carga** (ETL) desarrollado en SQL Server Integration Services (SSIS) para alimentar nuestro almacén de datos.

2.1. Fuentes de Datos Adicionales

Para complementar la información relacional de *openfootball* y cumplir con los requisitos del proyecto, se buscaron y extrajeron fuentes de datos adicionales en formato CSV. Estas fuentes externas permitieron enriquecer el almacén con los siguientes atributos:

- **Datos de Equipos (*datos_dim_teams.csv*):** Incorpora el continente de procedencia de cada club, permitiendo agrupaciones geográficas a gran escala.
- **Datos de Estadios (*datos_dim_estadios.csv*):** Introduce la capacidad de aforo de los estadios, lo cual añade una métrica física esencial para analizar la infraestructura de los encuentros.
- **Datos Temporales (*datos_dim_time.csv*):** Proporciona un calendario precalculado con cortes por año, trimestre, mes, día y día de la semana.

2.2. Autogeneración de IDs y Estrategia de Carga

Para asegurar la independencia del almacén respecto al sistema operativo de origen, **los IDs de todas las tablas de dimensiones son autogenerados**.

Esta decisión se implementó definiendo las claves primarias (*team_id*, *ground_id*, *event_id*, *jornada_id*, *date_key*) con la propiedad **IDENTITY(1,1)** en las tablas de destino de la base de datos del almacén. De esta forma, al realizar la importación mediante Integration Services, el propio motor de SQL Server asigna automáticamente un identificador secuencial único a cada registro.

Para garantizar la integridad referencial, el orden de ejecución del proceso ETL sigue una secuencia estricta:

1. **Fase 1: Carga de Dimensiones.** Se ejecutan en paralelo o de forma secuencial las tareas que limpian y cargan las tablas de dimensiones (*Dim_Teams*, *Dim_Grounds*, *Dim_Events*, *Dim_Jornada* y *Dim_Time*) utilizando los archivos CSV enriquecidos y las tablas origen.

2. **Fase 2: Carga de la Tabla de Hechos.** Una vez que las dimensiones tienen sus claves autogeneradas listas, se ejecuta la carga de la tabla de hechos **Partido**, realizando las búsquedas (*Lookups*) correspondientes para asociar cada encuentro con sus respectivas claves de dimensión.

2.3. Diseño del ETL en Integration Services (SSIS)

El paquete de Integration Services se estructuró mediante tareas claras en el Flujo de Control (*Control Flow*) y Flujos de Datos (*Data Flow*) individuales:

- **Flujo de Control:** Coordina el orden de las tareas mediante restricciones de precedencia, asegurando que la tabla de hechos no se cargue hasta que todas las dimensiones se hayan completado correctamente.
- **Flujo de Datos:** Por cada tabla, se configuró un origen de datos (las tablas relacionales o los archivos de texto CSV), componentes de transformación o conversión de tipos si era necesario, y un destino de SQL Server.

[SUGERENCIA DE CAPTURAS PARA ESTE APARTADO]:

1. *Captura del **Flujo de Control (Control Flow)** general en Visual Studio, donde se vean los recuadros de carga conectados con flechas verdes.*
2. *Captura de un **Flujo de Datos (Data Flow)** (por ejemplo, el de Estadios o Equipos) mostrando el origen CSV y el destino de base de datos.*

Tarea 3. Análisis de datos

En este apartado se describe el proceso de creación del cubo analítico en **SQL Server Analysis Services (SSAS)** y la posterior explotación de los datos mediante el lenguaje de consultas **MDX**. El objetivo de esta tarea es estructurar la información para permitir un análisis multidimensional rápido y avanzado.

3.1. Creación y Configuración del Cubo Analítico

A partir de la base de datos de nuestro almacén, importamos las tablas en SSAS para modelar el cubo denominado **Futbol DW**. En este proceso realizamos dos acciones principales:

1. **Definición de Medidas:** Establecemos las métricas cuantitativas que utilizaremos para los análisis. Entre ellas se incluyen el volumen de partidos (**Recuento Partido**), el cómputo global de anotaciones (**Total Goles**), los desgloses por bando (**Goles Local**, **Goles Visitante**) y los resultados específicos (**Empates**, **Victoria Local**, **Victoria Visitante**).
2. **Creación de Jerarquías de Usuario:** Para facilitar la navegación por los datos y permitir un análisis jerárquico descendente (*drill-down*), agrupamos los atributos de las dimensiones en las siguientes jerarquías de usuario:
 - **Calendario Temporal:** Organizado en los niveles de **Anio** -> **Trimestre** -> **Mes** -> **Dia**, complementado con un atributo específico para el **Nombre día semana**.
 - **Competición:** Estructurado en los niveles **Competicion** -> **Temporada**.
 - **Jornadas:** Una estructura que desglosa el **Evento** -> **Orden jornada** -> **Jornada**.
 - **Geografía de Equipos:** Permite agrupar los datos por zonas geográficas tanto para el equipo local (**Team1**) como para el visitante (**Team2**).
 - **Ubicación de Estadios:** Filtra y agrupa los encuentros según el recinto deportivo en el que se disputaron.

3.2. Explotación del Cubo mediante Consultas MDX

Una vez desplegado el cubo, diseñamos y ejecutamos un total de 15 consultas MDX con el fin de extraer respuestas a preguntas de negocio complejas.

Para que la memoria sea legible y no se sature de código innecesario, hemos agrupado las consultas realizadas en tres grandes bloques analíticos según su objetivo:

- **Bloque 1: Análisis General y Evolución Temporal (Consultas 1 a 5, 10, 11 y 15):** Estas consultas se centran en obtener grandes volúmenes de datos consolidados (totales de partidos y goles) y estudiar su comportamiento a lo largo del tiempo. Nos permiten ver qué años o temporadas fueron más goleadoras o en qué meses se concentra la actividad.
- **Bloque 2: Rendimiento y Comparativa de Equipos (Consultas 6 a 9):** Analizan el comportamiento de los clubes distinguiendo su rol como local o visitante. Con ellas creamos rankings (*Top 15*) de los equipos más efectivos en casa y fuera de ella, y evaluamos los porcentajes de victoria por club.
- **Bloque 3: Infraestructura y Calendario Especial (Consultas 12 a 14):** Se enfocan en extraer estadísticas ligadas a los estadios (cuáles acumulan más partidos o goles) y a las jornadas para identificar dinámicas específicas del campeonato.



Recomendación de Capturas de Pantalla para esta sección

Una captura de la estructura del cubo **Fútbol DW** dentro de Visual Studio (donde se vea el árbol de dimensiones y el grupo de medidas).

Una captura de SQL Server Management Studio (SSMS) ejecutando una de las consultas MDX, mostrando la cuadrícula con los resultados devueltos por el cubo.